



2024

XIII CONGRESSO/CONGRESO IBEROAMERICANO DE ACÚSTICA

Santiago de Chile, 2–4 diciembre 2024

Segmentación de sonidos pulmonares orientado a la extracción de información

González-Marrugo, M. R.¹; Ugarte, J. P.²

^{1,2} Universidad de San Buenaventura, Medellín, Colombia, maria.gonzalezma@tau.usbmed.edu.co, juan.ugarte@usbmed.edu.co

Resumen

La segmentación de los ciclos respiratorios es clave en el análisis computacional de sonidos respiratorios, generalmente realizada de manera manual por expertos médicos. Sin embargo, también existen algoritmos que permiten segmentar automáticamente, aunque su efectividad en esquemas de procesamiento digital de señales no ha sido suficientemente evaluada. Este estudio compara la eficacia de la segmentación manual y automática en la extracción de información cuantitativa para el análisis de señales respiratorias. Para ello, se diseñaron tareas de clasificación supervisada de ruidos respiratorios. Las características acústicas se extrajeron de los ciclos respiratorios segmentados manualmente correspondientes a la base de datos ICBHI y de forma automática usando un algoritmo reportado en la literatura. Se identificaron los modelos de clasificación con mejor capacidad de generalización para cada tipo de segmentación y se evaluaron en la base de datos CoCross. Los resultados sugieren que la segmentación manual resulta ofrece un mejor rendimiento en la clasificación de ruidos respiratorios. Sin embargo, las diferencias de rendimiento entre ambas técnicas segmentación no son marcadamente significativas, lo que sugiere que la segmentación automática podría ser una alternativa viable para el análisis de señales respiratorias. Futuros estudios deberán validar estas conclusiones.

Palabras claves: características acústicas, análisis Cepstral, aprendizaje supervisado, ruidos respiratorios.

1. Introducción

La evaluación de la salud pulmonar tradicionalmente se ha basado en la auscultación [1]. Esta técnica, valorada por su bajo costo, su naturaleza no invasiva y su aplicación en entornos no hospitalarios, sigue siendo esencial en la práctica médica. Sin embargo, su efectividad depende de la habilidad de un oyente experto para distinguir eventos acústicos específicos durante la respiración, lo que limita su objetividad y dificulta su aplicación remota [2]. Con el desarrollo de estetoscopios electrónicos, se habilita la posibilidad de almacenar los registros para una análisis posterior y aplicar técnicas computacionales de procesamiento de señales, lo que aporta mayor objetividad a la interpretación clínica [3]. En la última década, ha habido un crecimiento significativo en la investigación orientada a desarrollar nuevas técnicas para extraer información clínica útil a partir de registros respiratorios [4, 5].

Los ruidos respiratorios como *Crackles*, *Wheezes* y ronquidos están asociados a patologías pulmonares, por lo que su detección durante la auscultación es crucial para el diagnóstico. Estos ruidos presentan características acústicas distintivas, como patrones tonales y energéticos, que permiten su identificación durante el examen clínico [6]. El desarrollo de técnicas computacionales para la extracción y análisis información relevante para la detección y clasificación de ruidos pulmonares ha generado nuevas necesidades [5]. Una de estas necesidades es la segmentación de los ciclos respiratorios en los registros de sonidos obtenidos por auscultación, tarea que presenta desafíos debido a la dificultad de capturar adecuadamente la amplitud de las fases respiratorias, ya que el sonido resulta enmascarado por la capacidad absorbente de la caja torácica [2]. Aunque esta segmentación suele ser realizada de forma manual por médicos

expertos, se han explorado métodos computacionales que emplean mediciones de flujo de aire o sonidos traqueales para identificar los ciclos [1, 7, 8]. No obstante, poco se ha investigado sobre las diferencias entre la segmentación manual y computarizada. Más aún, no se ha caracterizado el impacto que tiene cada tipo de segmentación dentro de esquemas computarizados de análisis de señales respiratorias.

Por lo antes expuesto, este trabajo propone una evaluación comparativa entre la segmentación manual y la computarizada. Para este propósito, el trabajo aprovecha la base de datos de libre acceso *International Conference on Biomedical and Health Informatics* (ICBHI) [9], la cual es única en el campo de sonidos respiratorios, ya que los ciclos respiratorios en sus señales fueron segmentados por médicos especialistas, con etiquetas que indican la presencia o ausencia de ruidos respiratorios en cada ciclo. Este estudio plantea un diseño experimental basado en varias tareas de clasificación supervisada de ruidos respiratorios, utilizando como insumo de entrada las señales segmentadas en ciclos respiratorios. A través de este enfoque, se busca caracterizar la efectividad de las segmentaciones manual y automatizada en la extracción de información cuantitativa útil para el análisis de señales respiratorias.

2. Metodología

La metodología propuesta se compone de tres elementos: las bases de datos con registros de sonidos respiratorios, el proceso de segmentación de ciclos respiratorios, y un esquema de evaluación de la efectividad de la segmentación mediante modelos de clasificación supervisada. En la Figura 1 se presenta un diagrama de bloques que ilustra de manera resumida los componentes metodológicos y su interacción a lo largo de este trabajo.




Figura 1: Metodología empleada en este trabajo según tres componentes: bases de datos, segmentación de ciclos respiratorios y validación de la segmentación.

2.1 Bases de datos

Se emplearon dos bases de datos de sonidos respiratorios de acceso libre. La base de datos ICBHI 2019 [9] contiene 920 registros correspondientes a 126 pacientes. Las señales están etiquetadas en función de los ciclos respiratorios y la ocurrencia de ruidos pulmonares. Dichas etiquetas, asignadas por médicos expertos, especifican en segundos el inicio y el final de cada ciclo respiratorio presente en la señal y se designa como segmentación A. La base de datos incluye un total de 6898 ciclos, de los cuales 1864 se clasifican como *Crackles*, 886 como *Wheezes*, 506 como *Cracklewheez* (ambos eventos *Crackles* y *Wheezes*) y 3642 como *None* (sin eventos). Para el uso de esta base de datos, los registros fueron remuestreados a una frecuencia de muestreo uniforme de 4 kHz.

La base de datos CoCross 2022 [10], que recopila datos cardio-pulmonares de la 1ª UCI del Hospital “G. Papanikolaou” en Salónica, Grecia, durante la pandemia de SARS-CoV-2. Esta base de datos corresponde a múltiples registros tomados desde diferentes posiciones torácicas para 172 pacientes con una frecuencia de muestreo de 4 kHz. Además, contiene 3343 registros pulmonares, de los cuales 375 corresponden a *Crackles*, 55 a *Wheezes* y 411 a *None*. Estos registros no contienen la identificación de los segmentos correspondientes a los ciclos respiratorios, y la ocurrencia de ruidos pulmonares está asignada al registro completo sin especificar a qué ciclo respiratorio o segmento de la señal pertenecen.

2.2 Segmentación Pal-Barney

Pal y Barney [11] proponen un método para la identificación de fases respiratorias utilizando el filtro de Savitzky y Golay, el cual permite obtener la segunda derivada de la señal a partir de una versión suavizada de la misma [12]. Su esquema de segmentación de las fases inspiratoria y espiratoria se basa en la detección de picos y valles asociados a los transitorios lentos de la señal, y se desarrolla en cinco etapas. Primero, se aplica el filtro Savitzky-Golay para estimar la segunda derivada de un segmento de la señal, empleando un polinomio de grado 4 y 9 coeficientes, lo que corresponde a una ventana de 2 ms de duración, con órdenes de derivación 0, 1 y 2, tal como se reporta en [13]. Segundo, el valor absoluto de la segunda derivada se normaliza dentro de un rango de 0 a 1. Tercero, se corrigen los picos de gran amplitud, que podrían estar relacionados con *Crackles*, artefactos de movimiento, sonidos cardíacos, entre otros, los cuales podrían interferir en la correcta detección de las fases respiratorias. Esta corrección se realiza recortando los picos del valor absoluto normalizado de la segunda derivada que superan un umbral. Dicho umbral se determina para cada señal como el valor que acumula el 80 % del área bajo la curva definida por el histograma [14], y se estableció tras varias pruebas numéricas que demostraron resultados satisfactorios. En la cuarta etapa, se aplica un filtro pasa-bajos con una frecuencia de corte de 2.5 Hz para pacientes con comorbilidades y de 1 Hz para sujetos sanos, obteniéndose así la señal Λ . Finalmente, en la última etapa, las fases respiratorias se estiman a partir de los picos $\mathcal{M}$ y los valles $\mathcal{V}$ que cumplen con los siguientes criterios:

$$\mathcal{M} = \{x \in \Lambda \mid x \geq R(\Lambda) + 0,5 \cdot \sigma(\Lambda)\}, \quad (1)$$

$$\mathcal{V} = \{x \in \Lambda \mid x < R(\Lambda)\}, \quad (2)$$

donde $R(\Lambda)$ y $\sigma(\Lambda)$ son la raíz cuadrática media y la desviación estándar de la señal Λ , respectivamente. Estas relaciones afectan directamente la cantidad de picos y valles seleccionados, lo que influye en la detección de las fases respiratorias y en la duración de los ciclos identificados. De los valles identificados, se consideran únicamente aquellos que preceden y que siguen inmediatamente a cada pico. En caso de que no se detecte un valle antes del primer pico, se usa la primera muestra de la señal; de manera similar, si no hay un valle después del último pico, se emplea la última muestra de la señal. Los valles situados a menos de 200 ms de un pico son descartados, lo que permite que varíe la duración de los ciclos respiratorios. Adicionalmente, cualquier valle que se encuentre a menos de 500 ms de otro valle es eliminado del análisis. En el caso de que haya más de un pico entre dos valles, solo se considera el de mayor amplitud.

Posteriormente, los valles restantes se conectan alternando ciclos positivos y negativos de una onda cuadrada, comenzando siempre con un ciclo positivo. Generalmente, se considera que los ciclos respiratorios completos inician con la fase inspiratoria, por lo que el primer ciclo detectado se asume como inspiratorio. Sin embargo, esta suposición se corrige verificando que cada pico de la fase inspiratoria cumpla con criterios definidos mediante el umbral $\mathcal{U}_T$, dado por la siguiente ecuación:

$$\mathcal{U}_T = \frac{\mathcal{U}_A}{2} + \mathcal{U}_\sigma, \quad (3)$$

donde $\mathcal{U}_A$ representa la amplitud promedio de los picos restantes y $\mathcal{U}_\sigma$ es la desviación estándar de los mismos. Si una fase inspiratoria contiene un pico con amplitud es mayor a $\mathcal{U}_T$, esta se considera como una fase inspiratoria correcta. No obstante, si no contiene picos, o el pico tiene una amplitud menor o igual a $\mathcal{U}_T$, se descarta el valle previo a esa fase inspiratoria candidata, y los valles restantes se reconectan generando una nueva onda cuadrada (iniciando nuevamente con un ciclo positivo), conservando las fases inspiratorias previamente verificadas y redefiniendo las candidatas para la posterior verificación.

El proceso de verificación se completa cuando todos los ciclos positivos de la onda cuadrada contienen un pico con una amplitud superior a $\mathcal{U}_T$. Al finalizar, todos los ciclos positivos se consideran fases inspiratorias verificadas, mientras que los ciclos negativos, con o sin picos, se consideran fases espiratorias verificadas. Esta segmentación se aplica a la base de datos ICBHI, que se designa como B , y a la base de datos CoCross, que se designa como Γ .

2.3 Evaluación de la segmentación a partir de clasificación supervisada

Para evaluar la efectividad de la información de la segmentación A y B , se adopta un esquema de clasificación supervisada. Para este propósito, se implementa un proceso de extracción y selección de características, y entrenamiento y validación de máquinas de aprendizaje.

2.3.1 Extracción de características acústicas

Se extrajeron características espectrales y cepstrales para cada ciclo respiratorio definido por A , B y Γ , resultando en los espacios de características X_A , X_B y X_Γ , respectivamente. La m -ésima característica se estima en ventanas móviles de 30 ms de duración y un solapamiento de 20 ms, lo que permitió extraer varias características por ciclo respiratorio. A partir de este conjunto, se calculan tres valores representativos: el promedio (μ_m), desviación estándar (σ_m) y coeficiente de variación ($\gamma_m = \sigma_m / \mu_m$). En la Tabla 1 se listan las características obtenidas en este proceso, sumando un total de 159.

Tabla 1: Lista de descriptores espectrales y cepstrales de audio. Los tres índices por característica se refieren μ_m , σ_m y el coeficiente de variación (γ_m) de cada ciclo respiratorio.

Espacio de características (X)	Índice de característica m	Descriptor
Espectrales	1, 2, 3	<i>Spread</i>
	4, 5, 6	<i>Centroid</i>
	7, 8, 9	<i>Skewness</i>
	10, 11, 12	<i>Kurtosis</i>
	13, 14, 15	<i>Entropy</i>
	16, 17, 18	<i>Flatness</i>
	19, 20, 21	<i>Flux</i>
	22, 23, 24	<i>Crest</i>
	25, 26, 27	<i>Slope</i>
	28, 29, 30	<i>Decrease</i>
	31, 32, 33	<i>Rolloff point</i>
Cepstrales	34, ..., 75	MFCC 1–MFCC 14
	76, ..., 117	Δ MFCC 1– Δ MFCC 14
	118, ..., 159	$\Delta\Delta$ MFCC 1– $\Delta\Delta$ MFCC 14

2.3.2 Selección de características

Se implementa un esquema de selección de características híbrido que combina el filtrado por correlación con el algoritmo ReliefF. Para el filtrado por correlación, se estimó el coeficiente de correlación de Pearson $R_{m,p}$ para cada par de vectores de características (m, p) . Con el objetivo de evitar características con correlación fuerte, se estableció un umbral ρ , descartándose el vector de características X_p si $|R_{m,p}| > \rho$,

$m \neq p$. En este trabajo, se aplicó un umbral de $\rho = 0,8$.

El algoritmo ReliefF asigna pesos a las características según su relevancia predictiva [15]. Características que presentan alta variabilidad dentro de la misma clase se penalizan, mientras que aquellas que diferencian mejor entre clases se recompensan. La ponderación de las características depende del número de vecinos más cercanos κ . Para un conjunto de características X , los pesos $w_{m,\kappa}$ de la m -ésima característica se calculan para $\kappa = \{1, 2, \dots, 200\}$, y la variabilidad de los pesos se evalúa utilizando la diferencia absoluta media entre curvas de pesos de ponderación. El parámetro κ se ajusta identificando el valor a partir del cual la variabilidad entre curvas de ponderación se estabiliza. Las características se ordenan de mayor a menor peso y el subconjunto relevante Z de características se selecciona mediante el método del codo.

Después de aplicar el filtrado de correlación y el algoritmo ReliefF con $\kappa = 52$, a los espacios de características X_A y X_B , se identificaron las características relevantes Z_A y Z_B , respectivamente.

2.3.3 Aprendizaje supervisado

La evaluación de la segmentación se realizó mediante modelos de aprendizaje supervisado, utilizando los espacios de características seleccionadas Z_A y Z_B para los diferentes problemas de clasificación binaria que se enuncian en las Tablas 2 y 3. Para identificar el modelo con mejor capacidad de generalización, se implementó un esquema de validación *holdout* con 10 repeticiones. En cada repetición, el espacio de características se dividió en subconjuntos de entrenamiento (70 %) y de prueba (30 %). Para cada tarea de clasificación binaria, se seleccionó el modelo con el mejor rendimiento, denominado en adelante como *best case*, que luego fue entrenado con el 100 % de los datos para evaluar la segmentación B en la base datos CoCross.

Entre los modelos de aprendizaje supervisado utilizados se incluyeron los árboles de decisión, clasificadores *naive* Bayesianos, máquinas de soporte vectorial (SVM), regresión logística, análisis discriminante, clasificadores KNN (*k-nearest neighbors*) y redes neuronales (NN).

Tabla 2: Cantidad de observaciones de Z_A empleadas durante el entrenamiento y prueba de las máquinas.

Clase	Observaciones	Total
<i>Event-None</i>	3256-3642	6898
<i>Crackle-None</i>	1864-3642	5506
<i>Wheezes-None</i>	886-3642	4528
<i>Cracklewheez-None</i>	506-3642	4152
<i>Crackle-Wheezes</i>	1864-886	2750

Tabla 3: Cantidad de observaciones de Z_B empleadas durante el entrenamiento y prueba de las máquinas.

Clase	Observaciones	Total
<i>Event-None</i>	3091-3743	6834
<i>Crackle-None</i>	1825-3743	5568
<i>Wheezes-None</i>	792-3743	4535
<i>Cracklewheez-None</i>	474-3743	4217
<i>Crackle-Wheezes</i>	1825-792	2617

2.4 Métricas de rendimiento

El rendimiento de la segmentación B se evaluó considerando los verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN). Para identificar los ciclos detectados como verdaderos, se estableció un umbral de tolerancia de $\pm 1,40$ s para los TP, basado en la duración promedio de un ciclo respiratorio en la base de datos ICBHI, que es de $2,73 \pm 1,21$ s [9]. Este umbral se aplicó comparando los tiempos de inicio y fin de los ciclos detectados con los ciclos verdaderos; si la diferencia está dentro de la tolerancia, se clasifica como TP. De lo contrario, se marca como FP, mientras que los ciclos detectados que exceden la cantidad de ciclos verdaderos fueron clasificados como FN. Posteriormente, se realizó el etiquetado de la segmentación detectada. Los sonidos pulmonares etiquetados en A se asocian a los ciclos detectados en B cuyo intervalo temporal coincidiera con la etiqueta correspondiente.

El rendimiento de clasificación automática se midió en términos de precisión ($\mathcal{P}$), sensibilidad ($\mathcal{S}$) y el *F1-Score* ($\mathcal{F}$). Para los modelos entrenados, los valores de TP, FP y FN se obtuvieron a partir de las matrices de confusión generadas en las pruebas. Las métricas de rendimiento de clasificación se

calcularon para cada clase individual, y el promedio de estas se consideró como el rendimiento global.

3. Resultados

Se obtuvieron los resultados conforme a la metodología planteada. Primero, se extrajeron los ciclos respiratorios de las bases de datos ICBHI y CoCross aplicando el algoritmo de segmentación Pal-Barney. Luego, se evaluó la efectividad de la segmentación a partir de los modelos de clasificación supervisada, para lo cual se extrajeron y seleccionaron las características espectrales y cepstrales de cada segmento, se entrenaron los modelos de clasificación supervisada y se hallaron sus métricas de rendimiento de clasificación.

3.1 Segmentación de ciclos respiratorios

Se obtuvo la segmentación B , cuyos resultados se comparan con la referencia de la segmentación A . La Figura 2 presenta cuatro resultados representativos, donde la segmentación B se indica con una línea de color, mientras que la segmentación A se representa mediante áreas sombreadas. Para distinguir ciclos consecutivos, se alternan los colores verde y rojo. En la Figura 2a, se observa una alta concordancia entre las segmentaciones B y A , mientras que en la Figura 2b, aunque B detecta un número similar de segmentos respecto a A , existe un desfase significativo entre ambos. Las Figuras 2c y 2d muestran casos en los que el número de segmentos detectados por B es inferior o superior, respectivamente al número de segmentos detectados por A .




Figura 2: Ciclos respiratorios según la segmentación A (áreas sombreadas) y B (línea de color). (a) Alta coincidencia entre A y B , (b) desfase entre las segmentaciones A y B , (c) B detecta menos segmentos que A , (d) B detecta más segmentos que A .

Considerando los escenarios ilustrados en la Figura 2, se evaluó el rendimiento de la segmentación B , con los siguientes resultados: $\mathcal{S} = 88,80\%$, $\mathcal{P} = 71,26\%$ y $\mathcal{F} = 79,07\%$. Además, de 6898 ciclos

respiratorios registrados en ICBHI, 6834 fueron detectados en la segmentación B . En [11], los autores calculan el rendimiento de la segmentación B en función del número de ciclos respiratorios detectados, sin considerar la precisión en la identificación exacta del inicio y final de cada ciclo. Los rendimientos reportados son: $\mathcal{S} = 92,51\%$, $\mathcal{P} = 91,09\%$ y $\mathcal{F} = 90,78\%$. Sin embargo, en este trabajo, se ha validado la segmentación B considerando tanto la precisión en la detección del inicio como del final de cada ciclo respiratorio. En términos de sensibilidad $\mathcal{S}$, los resultados obtenidos en este estudio son comparables a los reportados por Pal y Barney. Sin embargo, en lo que respecta a la precisión $\mathcal{P}$, los valores obtenidos aquí son casi 20 puntos porcentuales más bajos. En [11], los autores emplean una base de datos híbrida compuesta por auscultaciones tomadas *in situ* y registros de acceso abierto, probando su algoritmo en sujetos sanos, pacientes con comorbilidades y registros que contienen *wheezes*. No obstante, mencionan que algunos registros fueron descartados debido a la inaudibilidad de las fases respiratorias. En contraste, en este trabajo no se descarta ningún registro. Se consideran señales con alto contenido de ruido, lo que dificulta la detección precisa de picos y valles e impacta directamente en la precisión de la segmentación, incrementando el número de falsos positivos detectados. Nuestra validación incluye señales con alta variabilidad, que abarcan diferentes tipos de ruidos pulmonares y ruido de fondo característico del entorno de auscultación.

Finalmente, para evaluar la efectividad de la segmentación, se etiquetaron los segmentos detectados utilizando los metadatos de ruidos pulmonares de la base de datos ICBHI en cada segmento definido por A . Como resultado, se observó una disminución en el número de eventos de tipo *Crackles*, *Wheezes* y *CrackleWheez* en un 2,09%, 10,61% y 6,32%, respectivamente. La clase *None* resultó en un incremento del 2,77%. Estas variaciones no representan una desviación significativa de lo caracterizado en la base de datos ICBHI.

3.2 Evaluación de la efectividad de la segmentación

Para evaluar la efectividad de la segmentación, se adopta un enfoque de clasificación supervisada de ruidos pulmonares. En primer lugar, se comparan los rendimientos de clasificación de los modelos de clasificación que utilizan como insumo de entrada las segmentaciones A y B aplicadas a las señales de la base de datos ICBHI. En segundo lugar, se procesa la base de datos CoCross con el algoritmo B obteniendo la segmentación Γ , y se evalúan las predicciones de los modelos entrenados con las características extraídas a partir de las segmentaciones A y B . La Figura 3 presenta los diagramas de caja de las características normalizadas, con promedio nulo y desviación estándar unitaria. Los estadísticos de cada característica –promedio (μ_m), desviación estándar (σ_m) y coeficiente de variación (γ_m)– se distinguen por los colores azul, rojo y amarillo, respectivamente. En general, se puede verificar una distribución heterogénea en los valores de las características espectrales y Cepstrales, mientras que las características Cepstrales delta (ΔMFCC) y delta–delta ($\Delta\Delta\text{MFCC}$) tienden a mostrar una distribución más homogénea.

3.2.1 Aprendizaje supervisado con base de datos ICBHI

Se aplicó el esquema híbrido de selección de características para las tareas de clasificación planteadas en la Tabla 2 a las características obtenidas mediante las segmentaciones A y B . Las Tablas 4 y 5 detallan los espacios de características seleccionadas Z_A y Z_B .

Tabla 4: Índices de las características que componen el conjunto Z_A y el número total de características.

Clase	m	Total
<i>Event-None</i>	13, 14, 24, 31, 32, 34, 37, 39, 40, 41, 43, 46, 49, 52, 55, 58, 64, 67, 70, 73, 82	21
<i>Crackle-None</i>	13, 14, 24, 31, 32, 34, 37, 39, 40, 41, 43, 46, 52, 55, 58, 61, 64, 67, 70, 73	20
<i>Wheezes-None</i>	14, 24, 32, 34, 37, 40, 41, 46, 49, 52, 55, 58, 61, 64, 67, 70, 73, 82	18
<i>Cracklewheez-None</i>	14, 32, 34, 37, 40, 41, 43, 46, 49, 52, 55, 58, 61, 64, 67, 70, 73, 106	18
<i>Crackle-Wheezes</i>	14, 24, 39, 41, 43, 44, 46, 49, 52, 55, 58, 61, 64, 67, 70, 73, 88, 100, 118	19




Figura 3: Diagramas de caja para las características acústicas extraídas de las segmentaciones $A(3a)$, $B(3b)$ y $\Gamma(3c)$. Los colores azul, rojo y amarillo representan la media, la desviación estándar y el coeficiente de variación calculados por ventanas de 30 ms con solapamiento de 20 ms.

Tabla 5: Índices de las características que componen el conjunto Z_B y el número total de características.

Clase	m	Total
<i>Event-None</i>	13, 14, 31, 32, 37, 40, 41, 43, 46, 49, 52, 55, 58, 61, 64, 67, 70, 73, 76, 79, 105, 132, 141, 147	24
<i>Crackle-None</i>	13, 14, 32, 37, 40, 41, 43, 46, 49, 52, 55, 58, 61, 64, 66, 67, 70, 73, 76, 115	20
<i>Wheezes-None</i>	14, 37, 40, 43, 46, 49, 52, 55, 58, 61, 64, 70, 73, 76, 79, 94, 106, 109, 121, 142, 148	21
<i>Cracklewheez-None</i>	14, 37, 39, 40, 41, 43, 46, 49, 52, 55, 58, 61, 64, 67, 70, 76, 79, 97, 124, 148	20
<i>Crackle-Wheezes</i>	13, 14, 37, 40, 41, 43, 46, 49, 52, 55, 58, 61, 64, 73, 76, 79, 85, 94, 106, 112, 142, 157	22

Para Z_A , la selección de características incluye predominantemente los estadísticos promedio de los

coeficientes MFCC, al menos un estadístico promedio de Δ MFCC y la entropía espectral. En el caso de Z_B , aunque se observa una tendencia similar en la selección de características, el esquema seleccionó un mayor número de estadísticos promedio de $\Delta\Delta$ MFCC. Esto sugiere que los coeficientes MFCC, en sus diferentes órdenes, son características candidatas para la clasificación de sonidos pulmonares, ya que son más sensibles a las variaciones en la señal.

Las características seleccionadas Z_A y Z_B se utilizan para entrenar las distintas máquinas de aprendizaje supervisado enunciadas en la metodología. Los casos *best case* corresponden al modelo *Fine KNN* con 1 vecino cercano y al modelo *Weighted KNN* con 10 vecinos cercanos, ambos configurados con la distancia Euclídea. Las métricas de rendimientos promedio de las repeticiones con el subconjunto de entrenamiento para cada tarea de clasificación se reportan en las Tablas 6 a 10. En general se observa que la segmentación A genera rendimientos de clasificación mayores respecto a la segmentación B. Las mayores diferencias en las métricas se observan para las tareas de clasificación *Wheezes–None* (Tabla 8) y *CrackleWheezes–None* (Tabla 9) donde se observan diferencias de más de 10 puntos porcentuales en las métricas globales. Por otro lado, la tareas de clasificación *Event–None* (Tabla 6) y *Crackle–None* (Tabla 7) son las que presentan menores diferencias que no sobrepasan los 6 puntos porcentuales.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	79,96 %	80,03 %	79,96 %	74,67 %	74,70 %	74,68 %
<i>Event</i>	77,71 %	80,82 %	79,22 %	72,07 %	72,69 %	72,37 %
<i>None</i>	82,22 %	79,24 %	80,69 %	77,27 %	76,72 %	76,99 %

Tabla 6: Métricas de rendimiento promedio sobre las 10 repeticiones de la validación *holdout* para la tarea de clasificación *Event–None*, de las máquinas *best case* *Fine KNN* y *Weighted KNN*, correspondientes a las segmentaciones A y B, respectivamente.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	80,89 %	81,01 %	80,94 %	76,01 %	75,40 %	75,68 %
<i>Crackle</i>	74,53 %	75,19 %	74,85 %	68,49 %	65,48 %	66,95 %
<i>None</i>	87,24 %	86,83 %	87,03 %	83,53 %	85,31 %	84,41 %

Tabla 7: Métricas de rendimiento promedio sobre las 10 repeticiones de la validación *holdout* para la tarea de clasificación *Crackle–None*, de la máquina *best case* *Weighted KNN*, para segmentaciones A y B.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	78,83 %	77,74 %	78,23 %	67,04 %	66,62 %	66,79 %
<i>Wheezes</i>	66,48 %	63,25 %	64,77 %	45,76 %	44,39 %	45,01 %
<i>None</i>	91,19 %	92,23 %	91,70 %	88,32 %	88,84 %	88,58 %

Tabla 8: Métricas de rendimiento promedio sobre las 10 repeticiones de la validación *holdout* para la tarea de clasificación *Wheezes–None*, de la máquina *best case* *Fine KNN*, para segmentaciones A y B.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	84,22 %	84,39 %	84,29 %	75,01 %	73,96 %	74,43 %
<i>CrackleWheez</i>	72,23 %	72,65 %	72,41 %	55,91 %	53,24 %	54,47 %
<i>None</i>	96,22 %	96,14 %	96,18 %	94,12 %	94,67 %	94,39 %

Tabla 9: Métricas de rendimiento promedio sobre las 10 repeticiones de la validación *holdout* para la tarea de clasificación *Cracklewheezes–None*, de la máquina *best case Fine KNN*, para segmentaciones A y B.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	84,01 %	81,85 %	82,76 %	76,23 %	74,84 %	75,43 %
<i>Crackle</i>	87,32 %	91,84 %	89,52 %	84,26 %	87,40 %	85,80 %
<i>Wheezes</i>	80,70 %	71,85 %	76,01 %	68,19 %	62,28 %	65,06 %

Tabla 10: Métricas de rendimiento promedio sobre las 10 repeticiones de la validación *holdout* para la tarea de clasificación *Crackle–Wheezes*, de la máquina *best case Fine KNN*, para segmentaciones A y B.

3.2.2 Predicción de ruidos respiratorios con base de datos CoCross

Los resultados de clasificación reportados en la sección 3.2.1 corresponden a los modelos *Fine KNN* y *Weighted KNN*, que demostraron la mejor capacidad de generalización. Estos modelos se entrenan con la base de datos ICBHI completa, con las segmentaciones A y B, y se evalúan con la base de datos CoCross, usando la segmentación Γ , donde se cuenta el número de ciclos respiratorios por registro. Las etiquetas de Γ se asignaron según los metadatos de la base de datos CoCross, que proporcionan una etiqueta única para cada registro de paciente, clasificando el tipo de ruido respiratorio. Estas etiquetas incluyen: *Wheezes*, ronquidos, *Crackles* finos, *Crackles* gruesos, chillidos, sonido tubular, ruidos pulmonares disminuidos, ruidos pulmonares ausentes *None* o frote pleural. Para el análisis, se seleccionaron los registros con presencia de *Crackles* (incluyendo finos y gruesos), *Wheezes* y *None*.

Para cada ciclo detectado en la segmentación Γ , se extrajo el espacio de características Z_Γ utilizando el conjunto de características Z_A y Z_B , con los cuales fueron entrenadas los modelos *best case*. El rendimiento de los modelos se calculó evaluando la predicción de ruidos pulmonares en los segmentos identificados en cada señal. Por ejemplo, en el caso de la tarea de clasificación *Crackle–None*, si un registro está etiquetado como *Crackle*, un TP ocurre cuando al menos uno de los ciclos detectados es correctamente clasificado como *Crackle*. Si ninguno de los ciclos detectados se predice como *Crackle*, se considera un FN. Si un ciclo etiquetado como *None* se clasifica erróneamente como *Crackle*, se cuenta como FP. Esta lógica se aplicó a cada tarea de clasificación, y las métricas de rendimiento por clase y globales se presentan en las Tablas 11 a la 14.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	57,07 %	75,76 %	63,19 %	61,56 %	72,52 %	62,34 %
<i>Event</i>	66,33 %	61,88 %	64,03 %	74,85 %	51,46 %	60,99 %
<i>None</i>	47,80 %	89,65 %	62,36 %	48,28 %	93,57 %	63,70 %

Tabla 11: Métricas de rendimiento de segmentación Γ predicha por la máquina *Fine KNN* entrenada con 100 % de segmentación A y *Weighted KNN* entrenada con 100 % de segmentación B para la tarea de clasificación *Event–None*.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	69,20 %	77,53 %	68,67 %	72,18 %	75,51 %	67,22 %
<i>Crackle</i>	85,95 %	57,94 %	69,22 %	92,12 %	51,26 %	65,87 %
<i>None</i>	52,45 %	97,13 %	68,12 %	52,23 %	99,76 %	68,56 %

Tabla 12: Métricas de rendimiento de segmentación Γ predicha por la máquina *Weighted KNN* entrenada con 100 % de segmentación A y B para la tarea de clasificación *Crackle–None*.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	76,07 %	93,66 %	83,51 %	75,72 %	93,01 %	83,14 %
<i>Wheezes</i>	63,80 %	92,16 %	75,40 %	63,45 %	89,90 %	74,39 %
<i>None</i>	88,34 %	95,17 %	91,63 %	88,00 %	96,12 %	91,88 %

Tabla 13: Métricas de rendimiento de segmentación Γ predicha por la máquina *Fine KNN* entrenada con 100 % de segmentación A y B para la tarea de clasificación *Wheezes–None*.

Clase	Segmentación A			Segmentación B		
	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$	$\mathcal{P}$	$\mathcal{S}$	$\mathcal{F}$
<i>Global</i>	54,96 %	88,93 %	60,84 %	54,72 %	89,07 %	61,43 %
<i>Crackle</i>	87,09 %	82,77 %	84,87 %	87,11 %	86,88 %	86,99 %
<i>Wheezes</i>	22,82 %	95,10 %	36,81 %	22,33 %	91,26 %	35,88 %

Tabla 14: Métricas de rendimiento de segmentación Γ predicha por la máquina *Fine KNN* entrenada con 100 % de segmentación A y B para la tarea de clasificación *Crackle–Wheezes*.

La mayor diferencia en la validación de la segmentación Γ se presenta en la tarea de clasificación *Crackle–None*, mientras que el mejor rendimiento de clasificación se observa en la tarea de *Wheezes–None*. Curiosamente, en las pruebas realizadas con la base de datos ICBHI, esta última tarea de clasificación muestra el rendimiento más bajo, como se detalla en las Tablas 6 a 10. Esta inconsistencia podría deberse a la estrategia adoptada para asignar las etiquetas en la base de datos CoCros durante la evaluación de rendimiento de clasificación. En general, los modelos entrenados con la segmentación A exhiben un mejor desempeño, lo que sugiere que el enfoque basado en la segmentación manual A es más confiable que el automatizado con B. Sin embargo, las diferencias de rendimiento no son marcadamente significativas en algunos casos.

Una de las principales limitaciones de este trabajo es la falta de un etiquetado manual en la base de datos CoCross que discrimine por ciclos respiratorios. Para mitigar este problema, se asumió que las predicciones debían reflejar únicamente el ruido respiratorio predominante en cada ciclo. No obstante, esta suposición puede no ser válida en todos los casos, ya que en la base de datos ICBHI se observó que un mismo registro puede contener diferentes tipos de ruidos respiratorios. Otra limitación radica en la ausencia de un procesamiento dedicado a la reducción de ruido y artefactos en las señales. Si bien esta decisión se justificó con el objetivo de preservar una mayor variabilidad en la base de datos, y los rendimientos obtenidos fueron satisfactorios, podría haber comprometido la consistencia de algunos resultados de clasificación. Al comparar los rendimientos de clasificación con los registros CoCross, se observó un mejor desempeño al discriminar entre *Wheezes* y *None*, en contraste con los resultados obtenidos con la base de datos ICBHI. Esta discrepancia puede deberse a que la base de datos CoCross contiene señales menos ruidosas. En estudios futuros, se incorporará una etapa de preprocesamiento en el esquema propuesto para mejorar la efectividad de los registros respiratorios.

4. Conclusiones

Este estudio comparó la segmentación manual y automática de ciclos respiratorios, evaluando su impacto en un esquema computacional de clasificación de ruidos respiratorios. Los resultados revelan que la segmentación manual proporciona una mejor caracterización de los sonidos respiratorios en procesos de clasificación supervisada, lo cual fue evidenciado en dos bases de datos diferentes. Según Sovijärvi [16], las características de estos ruidos varían según el diagnóstico y pueden manifestarse durante la inspiración o espiración, lo que resalta la importancia de una segmentación precisa para generar un análisis adecuado. No obstante, los resultados obtenidos muestran que las diferencias entre ambos tipos de segmentación no son drásticamente significativas, sugiriendo que la segmentación automática puede ser una alternativa viable en el análisis de señales respiratorias. Se requieren estudios adicionales para confirmar estas observaciones. Además, nuestro diseño experimental subraya la importancia de contar con bases de datos que incluyan ciclos respiratorios correctamente segmentados y etiquetados.

5. Agradecimientos

Los autores agradecen a la Sociedad Chilena de Acústica por la asignación de la beca SOCHA a la primera autora correspondiente a la gratuidad en la inscripción para el congreso FIA 2024. También agradecer a Samuel David Betancourt Marín por el apoyo técnico en la curación de las bases de datos usadas en este trabajo.

Referencias

1. Sarkar, Malay *et al.* *Auscultation of the respiratory system.* *Annals of Thoracic Medicine*, 10(3):158–168, 2015. doi: [10.4103/1817-1737.160831](https://doi.org/10.4103/1817-1737.160831).
2. Rao, Adam; Huynh, Emily; Royston, Thomas J.; Kornblith, Aaron y Roy, Shuvo. *Acoustic methods for pulmonary diagnosis.* *IEEE Reviews in Biomedical Engineering*, 12:221–239, 2019. doi: [10.1109/rbme.2018.2874353](https://doi.org/10.1109/rbme.2018.2874353).
3. Leng, Shuang; Tan, Ru San; Chai, Kevin Tshun Chuan; Wang, Chao; Ghista, Dhanjoo y Zhong, Liang. *The electronic stethoscope.* *BioMedical Engineering Online*, 14(1):1–37, 2015. doi: [10.1186/s12938-015-0056-y](https://doi.org/10.1186/s12938-015-0056-y).
4. Marques, Alda y Jácome, Cristina. *Future Prospects for Respiratory Sound Research.* *Em Priftis, Kostas N.; Hadjileontiadis, Leontios J. y Everard, Mark L., editores, Breath Sounds*, págs. 291–304. Springer International Publishing, Cham, 2018. ISBN 978-3-319-71823-1. doi: [10.1007/978-3-319-71824-8_16](https://doi.org/10.1007/978-3-319-71824-8_16).
5. Kim, Yoonjoo; Hyon, Yun Kyong; Lee, Sunju; Woo, Seong Dae; Ha, Taeyoung y Chung, Chaeuk. *The coming era of a new auscultation system for analyzing respiratory sounds.* *BMC Pulmonary Medicine*, 22(1):1–11, 2022. doi: [10.1186/s12890-022-01896-1](https://doi.org/10.1186/s12890-022-01896-1).
6. Pasterkamp, Hans; Brand, Paul L.P.; Everard, Mark; Garcia-Marcos, Luis; Melbye, Hasse y Priftis, Kostas N. *Towards the standardisation of lung sound nomenclature.* *European Respiratory Journal*, 47(3):724–732, 2016. doi: [10.1183/13993003.01132-2015](https://doi.org/10.1183/13993003.01132-2015).
7. Alshaer H, Fernie G. R., Bradley T.D. *Monitoring of breathing phases using a bioacoustic method in healthy awake subjects.* *Journal of Clinical Monitoring and Computing*, 26(4):383–389, 2012. doi: [10.1007/s10877-011-9307-z](https://doi.org/10.1007/s10877-011-9307-z).
8. Tarrant, Sarah C.; Ellis, R. E.; Flack, F. C. y Selley, W. G. *Comparative review of techniques for recording respiratory events at rest and during deglutition.* *Dysphagia*, 12:24–38, January 1997. doi: [10.1007/PL00009515](https://doi.org/10.1007/PL00009515).
9. Rocha, Bruno M.; Filos, Dimitris; Mendes, Luís; Serbes, Gorkem; Ulukaya, Sezer; Kahya, Yasemin P.; Jakovljevic, Nikša; Turukalo, Tatjana L.; Vogiatzis, Ioannis M; Perantoni, Eleni; Kaimakamis, Evangelos; Natsiavas, Pantelis; Oliveira, Ana; Jácome, Cristina; Marques, Alda; Maglaveras, Nicos; Pedro Paiva, Rui; Chouvarda, Ioanna y Carvalho, Paulo and. *An open access database for the evaluation of respiratory sound classification algorithms.* *Physiological Measurement*, 40(3):035001, 2019. doi: [10.1088/1361-6579/ab03ea](https://doi.org/10.1088/1361-6579/ab03ea).
10. Kaimakamis, Evangelos *et al.* *CoCross Covid-19 Lung Sounds Database.* <https://doi.org/10.6084/m9.figshare.23578719.v1>, 4 2024.
11. Pal, Ravi y Barney, Anna. *Automatic breathing phase identification based on the second derivative of the recorded lung sounds.* *Biomedical Signal Processing and Control*, 94:106315, 2024. doi: [10.1016/j.bspc.2024.106315](https://doi.org/10.1016/j.bspc.2024.106315).
12. Savitzky, A. y Golay, M. J. E. *Smoothing and differentiation of data by simplified least squares procedures.* *Analytical Chemistry*, 36(8):1627–1639, 1964.
13. Pal, Ravi y Barney, Anna. *Iterative envelope mean fractal dimension filter for the separation of crackles from normal breath sounds.* *Biomedical Signal Processing and Control*, 66:102454, 2021. doi: [10.1016/j.bspc.2021.102454](https://doi.org/10.1016/j.bspc.2021.102454).
14. Vannuccini, L.; Rossi, M. y Pasquali, G. *A new method to detect crackles in respiratory sounds.* *Technology and Health Care*, 6(1):75–79, 1998. doi: [10.3233/THC-1998-6109](https://doi.org/10.3233/THC-1998-6109).

15. Urbanowicz, Ryan J.; Meeker, Melissa; La Cava, William; Olson, Randal S. y Moore, Jason H. and. *Relief-based feature selection: Introduction and review*. Journal of Biomedical Informatics, 84:189–203, 2018. doi: [10.1016/j.jbi.2018.07.014](https://doi.org/10.1016/j.jbi.2018.07.014).
16. Sovijärvi, Anssi; Malmberg, L. P.; Charbonneau, G.; Vanderschoot, J.; Dalmasso, F.; Sacco, C.; Rossi, M. y Earis, J. E. *Characteristic of breath sounds and adventitious respiratory sounds*. Characteristics of Breath Sounds and Adventitious Respiratory Sounds, 10:591–596, 01 2000.